

**Predicción del Producto Interno Bruto (PIB) mediante Regresión Lineal  
utilizando indicadores económicos**

**Semana 4 – Taller: Herramientas de Recolección de Datos**

**Programa:** Especialización en Análisis y Ciencia de Datos

**Universidad:** Universidad de Cundinamarca

**Autor:** Yerson Ronaldo Rivas Ruiz

**Fuente de datos:** Banco Mundial – World Development Indicators

**Año de análisis:** 2023

**Modelo:** Regresión Lineal Múltiple

## 1. Resumen ejecutivo

El presente proyecto desarrolla un modelo de Regresión Lineal Múltiple para analizar en qué medida algunas variables demográficas y económicas permiten explicar y predecir el Producto Interno Bruto (PIB) de diferentes países y economías.

Los datos corresponden al año 2023 y fueron recolectados mediante la API oficial del Banco Mundial, utilizando indicadores del conjunto World Development Indicators. Se seleccionaron como variables predictoras la población, las exportaciones, las importaciones, el desempleo y la inflación, mientras que el PIB en dólares corrientes fue definido como variable objetivo.

Después de realizar la limpieza y exploración de los datos, se dividió el conjunto en 80 % para entrenamiento y 20 % para prueba, utilizando `random_state=42` para garantizar la reproducibilidad.

El modelo obtuvo un MAE de **\$987.607.462.377,57**, un RMSE de **\$2.063.286.354.110,32** y un  $R^2$  de **0,6333** en el conjunto de prueba. Esto indica que el modelo explica aproximadamente el 63,33 % de la variabilidad observada del PIB en dicho conjunto.

Los resultados deben interpretarse considerando las diferencias de escala entre las economías, la utilización de información de un solo año, la presencia potencial de valores extremos y las limitaciones propias de un modelo lineal.

## 2. Definición del problema

El Producto Interno Bruto (PIB) es uno de los principales indicadores utilizados para representar el tamaño de la actividad económica de un país. Su comportamiento está relacionado con diferentes factores demográficos y económicos.

En este proyecto se busca analizar en qué medida un conjunto de variables permite explicar y predecir el PIB de diferentes países y economías.

### Pregunta de investigación

**¿En qué medida algunas variables demográficas y económicas permiten explicar y predecir el PIB de los países?**

## **Objetivo**

Construir y evaluar un modelo de Regresión Lineal Múltiple utilizando el PIB como variable objetivo y cinco indicadores demográficos y económicos como variables predictoras.

## **3. Método de recolección de datos**

Los datos fueron obtenidos mediante la **API oficial del Banco Mundial**, utilizando indicadores pertenecientes al conjunto World Development Indicators (WDI).

Se seleccionó el año **2023** y se consultaron seis indicadores:

- Producto Interno Bruto.
- Población total.
- Exportaciones de bienes y servicios.
- Importaciones de bienes y servicios.
- Desempleo.
- Inflación.

La recolección se realizó mediante Python utilizando la biblioteca requests.

Posteriormente, los resultados fueron transformados en estructuras DataFrame mediante pandas.

Los diferentes indicadores fueron combinados utilizando como claves el código y el nombre del país o economía.

La utilización de una API permite mantener la trazabilidad de la fuente y facilita la reproducción del proceso de recolección.

## **Criterios de calidad**

Durante la preparación de los datos se verificaron:

- Valores faltantes.
- Registros duplicados.
- Estructura y tipos de datos.
- Consistencia de las variables seleccionadas.
- Diferenciación entre países/economías y registros agregados.

La clasificación disponible en la propia API del Banco Mundial fue utilizada para conservar los registros correspondientes a países y economías y excluir agregados regionales o grupos económicos del conjunto final utilizado para el modelamiento.

#### 4. Variables utilizadas

| Variable      | Código Banco Mundial | Descripción                                        | Tipo              |
|---------------|----------------------|----------------------------------------------------|-------------------|
| PIB           | NY.GDP.MKTP.CD       | Producto Interno Bruto en dólares corrientes       | Variable objetivo |
| Población     | SP.POP.TOTL          | Población total                                    | Predictora        |
| Exportaciones | NE.EXP.GNFS.ZS       | Exportaciones de bienes y servicios como % del PIB | Predictora        |
| Importaciones | NE.IMP.GNFS.ZS       | Importaciones de bienes y servicios como % del PIB | Predictora        |
| Desempleo     | SL.UEM.TOTL.ZS       | Desempleo como % de la fuerza laboral              | Predictora        |
| Inflación     | FP.CPI.TOTL.ZG       | Variación porcentual anual del IPC                 | Predictora        |


#### 5. Preparación y análisis exploratorio

La etapa de preparación incluyó la revisión de la estructura del conjunto de datos, valores faltantes y registros duplicados.


Posteriormente se realizó una depuración para excluir registros correspondientes a regiones y grupos económicos, conservando los países y economías identificados mediante la clasificación de la API del Banco Mundial.

El análisis exploratorio incluyó:


- Matriz de correlación.




- Gráfico de Relación entre población y PIB.



- Gráfico de Relación entre exportaciones y PIB.



- Gráfico de Relación entre importaciones y PIB.



Las estadísticas descriptivas permitieron identificar diferencias importantes en la magnitud de los indicadores entre las economías analizadas, especialmente en variables como PIB y población.

La matriz de correlación permitió observar las asociaciones lineales existentes entre el PIB y las variables predictoras.

Los gráficos de dispersión permitieron visualizar la distribución de las observaciones, posibles patrones y valores extremos.

La relación entre población y PIB resulta especialmente relevante como punto de exploración debido a que ambas variables están relacionadas con el tamaño de

las economías. Sin embargo, las asociaciones estadísticas observadas no deben interpretarse como relaciones causales.

## 6. Construcción del modelo

Se construyó un modelo de **Regresión Lineal Múltiple**.

### Variable objetivo

#### PIB

### Variables predictoras

- Población.
- Exportaciones.
- Importaciones.
- Desempleo.
- Inflación.

Los datos fueron divididos de la siguiente manera:

- **80 %**: conjunto de entrenamiento.
- **20 %**: conjunto de prueba.

Se utilizó `random_state=42` para facilitar la reproducibilidad de los resultados.

El modelo fue implementado utilizando la clase `LinearRegression` de la biblioteca `scikit-learn`.

### Coeficientes obtenidos

| Variable | Coeficiente |
|----------|-------------|
|----------|-------------|

|           |          |
|-----------|----------|
| Población | 5.570,38 |
|-----------|----------|

|               |               |
|---------------|---------------|
| Exportaciones | 9.040.080.000 |
|---------------|---------------|

| <b>Variable</b>   | <b>Coeficiente</b>        |
|-------------------|---------------------------|
| Importaciones     | -17.738.110.000           |
| Desempleo         | -20.532.460.000           |
| Inflación         | -2.411.009.000            |
| <b>Intercepto</b> | <b>965.190.768.680,37</b> |

### **Ecuación estimada**

$$\text{PIB} = 965.190.768.680,37 + 5.570,38(\text{Población}) + 9.040.080.000(\text{Exportaciones}) - 17.738.110.000(\text{Importaciones}) - 20.532.460.000(\text{Desempleo}) - 2.411.009.000(\text{Inflación})$$

Los coeficientes representan asociaciones dentro de la especificación estimada, manteniendo constantes las demás variables del modelo. No deben interpretarse como efectos causales.

Además, la magnitud de cada coeficiente depende de las unidades en las que se encuentra expresada la correspondiente variable.

## **7. Evaluación del modelo**

Para evaluar el comportamiento del modelo se utilizaron cuatro métricas:

- MAE.
- MSE.
- RMSE.
- $R^2$ .

### **Resultados**

#### **Métrica Resultado**

MAE    \$987.607.462.377,57


## Métrica Resultado

MSE \$4.257.150.579.057.866.024.419.328,00

RMSE \$2.063.286.354.110,32

R<sup>2</sup> 0,6333

- Gráfico de PIB real vs. PIB predicho



## Interpretación

El **MAE** indica que el error absoluto medio de las predicciones fue aproximadamente de **987,6 mil millones de dólares**.

El **RMSE** fue de aproximadamente **2,06 billones de dólares**. Esta métrica es particularmente sensible a errores grandes, por lo que puede verse influenciada por las diferencias de tamaño entre las economías analizadas.

El **MSE** corresponde al promedio de los errores cuadrados y, debido a que los errores se encuentran expresados en dólares, presenta una magnitud numérica considerablemente elevada.

El **R<sup>2</sup> fue de 0,6333**, lo que significa que el modelo explica aproximadamente el **63,33 % de la variabilidad observada del PIB en el conjunto de prueba**. El porcentaje restante corresponde a variabilidad que no es explicada por las variables incluidas en esta especificación.

Estos resultados describen el desempeño del modelo sobre los datos evaluados y no deben interpretarse como evidencia de relaciones causales.

## 8. Validación de los supuestos

La validación del modelo se realizó mediante diferentes representaciones gráficas.


### PIB real frente a PIB predicho

La comparación entre los valores reales y predichos permite observar visualmente qué tan próximas se encuentran las estimaciones del modelo respecto a las observaciones.

Una mayor proximidad a la línea de referencia representa una menor diferencia entre el valor observado y el estimado.

### Residuos frente a valores predichos

El análisis de residuos permite revisar la presencia de patrones sistemáticos en los errores.



Esta gráfica se utiliza principalmente para evaluar visualmente aspectos relacionados con la linealidad y la homocedasticidad.


Una distribución de los residuos alrededor de cero y sin patrones sistemáticos sería consistente con un comportamiento esperado del modelo.

### Histograma de residuos

El histograma permite observar la distribución de los errores e identificar posibles asimetrías o valores extremos.

Estas comprobaciones son principalmente gráficas y deben interpretarse teniendo en cuenta las características del conjunto de datos.

Debido a las grandes diferencias de escala del PIB entre países y economías, pueden existir patrones y valores extremos que dificulten la representación de todas las observaciones mediante una única relación lineal.



## 9. Conclusiones

El proyecto permitió construir un modelo de Regresión Lineal Múltiple utilizando información del Banco Mundial correspondiente al año 2023.

La metodología permitió integrar un proceso completo de recolección, limpieza, exploración, modelamiento y evaluación de datos.

El modelo utilizó población, exportaciones, importaciones, desempleo e inflación como variables predictoras del PIB.

En el conjunto de prueba se obtuvo un  **$R^2$  de 0,6333**, indicando que aproximadamente el 63,33 % de la variabilidad observada del PIB fue explicada por las variables incluidas en el modelo.

El MAE y el RMSE presentaron valores elevados en términos absolutos debido, entre otros aspectos, a que el PIB se encuentra expresado en dólares y existe una

diferencia considerable en el tamaño económico de los países y economías analizados.

Los coeficientes obtenidos permiten identificar asociaciones dentro del modelo, pero no deben interpretarse como relaciones causales.

## **10. Limitaciones**

El proyecto presenta las siguientes limitaciones:

- Se utilizó información correspondiente únicamente al año 2023.
- El PIB presenta diferencias de escala importantes entre economías.
- El modelo utiliza únicamente cinco variables predictoras.
- Pueden existir valores extremos que influyan en las estimaciones.
- La regresión lineal supone relaciones lineales entre las variables.
- Las asociaciones estadísticas no implican causalidad.
- El conjunto de prueba representa una cantidad limitada de observaciones.

Estas limitaciones deben tenerse en cuenta al interpretar los resultados y al considerar posibles aplicaciones del modelo.

## **11. Trabajo futuro**

Como posibles mejoras del proyecto se plantean las siguientes:

1. Incorporar información correspondiente a varios años.
2. Ampliar el número de variables económicas, sociales y demográficas.
3. Aplicar transformaciones logarítmicas al PIB debido a sus diferencias de escala.
4. Analizar y tratar de manera específica los valores extremos.
5. Implementar validación cruzada.

6. Comparar la regresión lineal con otros algoritmos de aprendizaje automático.
7. Evaluar diferentes especificaciones del modelo.
8. Incorporar indicadores adicionales relacionados con productividad, inversión, comercio y desarrollo económico.

## 12. Repositorio GitHub y reproducibilidad

El proyecto se encuentra organizado en un repositorio de GitHub con los archivos necesarios para reproducir el análisis.

### Estructura

Proyecto-regresion-pib/

```
|  
|  
|— datos/  
|   └─ dataset_regresion_pib_2023_limpio.csv  
|  
|— notebooks/  
|   └─ regresion_lineal_pib_2023.ipynb  
|  
|— informe/  
|   └─ Informe_RegresionLineal_RivasYerson.pdf  
|  
|— README.md  
└─ requirements.txt
```

### Repositorio

**Enlace al repositorio GitHub:**

[Proyecto-regresion-pib/informe/Informe RegresionLineal RivasYerson.pdf at main · jersonrivas0320-dev/Proyecto-regresion-pib](#)

El archivo requirements.txt contiene las principales dependencias utilizadas:

- pandas
- numpy
- requests
- scikit-learn
- matplotlib

La utilización de random\_state=42 permite mantener reproducible la división entre los conjuntos de entrenamiento y prueba.

### **13. Fuentes y referencias**

#### **Fuente de datos**

##### **World Bank – World Development Indicators (WDI)**

<https://datatopics.worldbank.org/world-development-indicators/>

##### **World Bank – Indicators API Documentation**

<https://datahelpdesk.worldbank.org/knowledgebase/articles/889392>

##### **World Bank – Indicator API Queries**

<https://datahelpdesk.worldbank.org/knowledgebase/articles/898599>

#### **Fuente académica**

##### **Universidad de Cundinamarca.**

*Introducción al Machine Learning: Una Guía Práctica.*

[https://posgrado.ucundinamarca.edu.co/pluginfile.php/79242/mod\\_label/intro/Introduccion-al-Machine-Learning-Una-Guia-Practica.pdf](https://posgrado.ucundinamarca.edu.co/pluginfile.php/79242/mod_label/intro/Introduccion-al-Machine-Learning-Una-Guia-Practica.pdf)

#### **Documentación técnica**

## **Scikit-learn.**

*Getting Started — scikit-learn documentation.*

[https://scikit-learn.org/stable/getting\\_started.html](https://scikit-learn.org/stable/getting_started.html)

## **Recursos audiovisuales**

### **Learning Scikit-Learn**

<https://www.youtube.com/watch?v=rvVkVsG49uU>

### **Tutorial: ¡SCIKIT-LEARN DESDE CERO!**

<https://www.youtube.com/watch?v=qUjlybMkXBs>

---

## **Autor**

**Yerson Ronaldo Rivas Ruiz**

Especialización en Análisis y Ciencia de Datos

Universidad de Cundinamarca